REPORTE TÉCNICO: PIPELINE DE DATOS Y ANÁLISIS DEL MERCADO INMOBILIARIO EN PLAYA

1. Arquitectura del Proyecto

El proyecto se diseñó bajo una arquitectura de recolección de datos de métodos mixtos, dividida en cuatro pilares fundamentales para garantizar la triangulación de la información:

· Pilar 1 (Mercado Informal): Web Scraping masivo de la plataforma Revolico (735 anuncios de toda La Habana).
· Pilar 2 (Mercado Formal): Extracción manual de 30 anuncios de catálogos web de agencias inmobiliarias (portal Casaoasis).
· Pilar 3 (Redes Sociales): Digitalización de 30 anuncios de grupos de compraventa en Facebook y WhatsApp.
· Pilar 4 (Mercado Real): Recolección primaria mediante 30 entrevistas presenciales en las calles de Playa.

2. Stack Tecnológico

· Lenguaje: Python 3.13.
· Librerías de Extracción: requests (peticiones HTTP), BeautifulSoup4 (parseo de HTML).
· Librerías de Manipulación: pandas, numpy, jsonlines.
· Librerías de Machine Learning y NLP: scikit-learn (K-Means, PCA, TF-IDF), re (expresiones regulares), unicodedata (normalización de texto).
· Librerías de Visualización: matplotlib, seaborn.
· Herramientas de Desarrollo: Git y GitHub Desktop (control de versiones), OpenCode (asistente de IA para generación y auditoría de código).

3. Pipeline ETL: Extracción (Extract)

· Web Scraping (Revolico): Se implementó un spider en Python que utiliza headers con User-Agents rotativos para simular un navegador real. Se incorporaron pausas aleatorias (delays) de 3 a 5 segundos entre peticiones para evitar bloqueos por rate limiting. Se extrajeron exitosamente 515 anuncios iniciales.
· Datos Manuales (Agencias y Redes): Dada la falta de APIs estructuradas en agencias cubanas, se diseñaron plantillas CSV/JSONL y se recolectaron 60 anuncios (30 de portales formales y 30 de redes sociales).
· Entrevistas (Pilar 4): Se digitalizaron 30 entrevistas presenciales estructuradas, convirtiendo las respuestas abiertas y cerradas a un formato de datos tabular para su análisis.

4. Pipeline ETL: Transformación y Limpieza (Transform)

· Migración a JSONL: Para evitar la desalineación de datos provocada por los saltos de

línea en las descripciones de los anuncios (común en archivos CSV), todos los datos fueron estandarizados y almacenados en formato JSON Lines (.jsonl).
· Auditoría de Outliers: Se detectaron y aislaron anomalías extremas. Se descartaron anuncios con precios basura (1 USD, 7 USD) y se auditó manualmente un registro con "70 baños" (error del vendedor). Las propiedades de lujo (>500k USD) se aislaron en un segmento lujo_top para no sesgar las medianas generales.
· Manejo de Nulos e Imputación: Los valores ausentes en habitaciones y baños se imputaron utilizando la mediana según el tipo de inmueble. Los registros sin metraje (m²) o sin barrio se mantuvieron como null (valores nulos).
· Corrección de Bugs:
· Falso positivo en NLP: Se detectó que el sistema marcaba "urgencia migratoria" erróneamente porque la palabra clave "visa" hacía match dentro de la palabra "avisando". Se corrigió implementando límites de palabra (\b) en las expresiones regulares.
· Estandarización geográfica: Se implementó un diccionario para mapear barrios coloquiales a municipios oficiales (ej. "Vedado" -> "Plaza de la Revolución", "Miramar" -> "Playa").

5. Modelado y Procesamiento de Lenguaje Natural (NLP)

· Clustering (K-Means): Se aplicó aprendizaje no supervisado para agrupar los anuncios según sus características numéricas (precio, habitaciones, baños). Se utilizó el Método del Codo para determinar el número óptimo de clústeres.
· NLP (TF-IDF): Se vectorizaron las descripciones de los anuncios para agruparlos según su perfil discursivo. El algoritmo identificó 4 clústeres claros (Casas Familiares, Anuncios de Agencias, etc.).
· Visualización (PCA): Se aplicó Análisis de Componentes Principales (PCA) para reducir la dimensionalidad de los datos y graficar los clústeres en 2D, permitiendo una interpretación visual de los grupos.

6. Limitaciones Técnicas y de Infraestructura

Durante la recolección de entrevistas, 4 personas se negaron a ser grabadas, pero sí a prestar su declaración, por lo tanto, fueron añadidos a la muestra, pero no quedó constancia a través de audio.

· Limitaciones de la API de Revolico: La API del sitio no expone las fechas de publicación ni el metraje (m²) en su estructura JSON. Esto obligó a extraer los m² mediante expresiones regulares sobre la descripción, resultando en un 65% de valores nulos y limitando el análisis de series temporales.
· Varianza del PCA: El modelo de NLP presentó una varianza explicada del 19.8% en sus dos primeros componentes. Esta baja varianza indica que el texto libre de los anuncios es altamente heterogéneo, lo que limitó la separación visual de los clústeres en el gráfico 2D (coeficiente de Silueta de 0.131).
· Prototipo Web: Se desarrolló un prototipo funcional (MVP) en un solo archivo

index.html (utilizando HTML, TailwindCSS y Vanilla JS) para demostrar cómo una plataforma con campos obligatorios podría mitigar la asimetría de información. Los datos del prototipo se manejan localmente mediante localStorage.